

Prediksi dan Pengelompokan Kualitas Udara Jakarta Menggunakan Random Forest dan K-Means Clustering

Tata Ivanka¹, Farrel Farica Firjaturazza²

¹ Program Studi S1 Sistem Informasi, Universitas Negeri Surabaya

124051214001@mhs.unesa.ac.id

² Universitas Negeri Surabaya, Indonesia

224051214034@mhs.unesa.ac.id

Abstrak — Kualitas udara merupakan salah satu indikator penting yang memengaruhi kesehatan masyarakat dan kualitas lingkungan, terutama di wilayah perkotaan dengan tingkat aktivitas manusia yang tinggi seperti Jakarta. Peningkatan jumlah kendaraan bermotor, aktivitas industri, pembangunan infrastruktur, serta pertumbuhan penduduk yang pesat berkontribusi terhadap meningkatnya konsentrasi polutan di udara. Kondisi tersebut dapat menimbulkan berbagai dampak negatif, mulai dari gangguan pernapasan hingga penurunan kualitas hidup masyarakat. Oleh karena itu, penelitian ini menerapkan pendekatan Data Mining untuk melakukan prediksi dan pengelompokan kualitas udara Jakarta menggunakan algoritma Random Forest Classifier dan K-Means Clustering. Metodologi yang digunakan adalah CRISP-DM yang terdiri atas tahapan Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Dataset penelitian diperoleh dari beberapa sumber terbuka, yaitu Kaggle dan Data.go.id, yang kemudian digabungkan dan diproses menjadi satu dataset terpadu. Parameter yang digunakan meliputi PM2.5, PM10, SO₂, CO, O₃, dan NO₂ sebagai variabel predictor. Hasil penelitian menunjukkan bahwa model Random Forest mampu menghasilkan performa yang sangat baik dengan Accuracy sebesar 98,20% dan F1 Macro sebesar 96,85%, sehingga layak digunakan untuk prediksi kategori kualitas udara. Selain itu, model K-Means menghasilkan empat cluster yang dapat diinterpretasikan sebagai tingkat polusi rendah, moderat, tinggi, dan ekstrem. Seluruh model kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit yang memungkinkan pengguna melakukan prediksi dan analisis kualitas udara secara interaktif. Hasil penelitian ini menunjukkan bahwa kombinasi metode classification dan clustering mampu memberikan informasi yang lebih komprehensif mengenai kondisi kualitas udara Jakarta.

Kata Kunci — Data Mining, Kualitas Udara, Random Forest, K-Means Clustering, CRISP-DM, Streamlit

I. PENDAHULUAN

Kualitas udara merupakan salah satu komponen lingkungan yang berpengaruh terhadap kesehatan dan kenyamanan masyarakat. Pada wilayah perkotaan dengan aktivitas ekonomi dan mobilitas tinggi, pencemaran udara dapat muncul dari emisi kendaraan bermotor, aktivitas industri, konstruksi bangunan, pembakaran bahan bakar, serta kepadatan penduduk. Jakarta sebagai pusat pemerintahan dan ekonomi Indonesia memiliki intensitas aktivitas yang tinggi sehingga pemantauan kualitas udara menjadi kebutuhan penting.

Polutan udara seperti PM2.5, PM10, SO₂, CO, O₃, dan NO₂ dapat digunakan untuk menggambarkan kondisi pencemaran udara. PM2.5 dan PM10 merupakan partikel yang dapat masuk ke saluran pernapasan, sedangkan SO₂, CO, O₃, dan NO₂ merupakan gas pencemar yang dapat terbentuk dari aktivitas pembakaran, reaksi kimia atmosfer, dan emisi transportasi. Kombinasi parameter tersebut memberikan gambaran lebih utuh mengenai kualitas udara suatu wilayah.

Berdasarkan data IQAir tahun 2025 yang digunakan sebagai penguat latar belakang, Jakarta berada pada peringkat ke-10 kota dengan kualitas udara terburuk di Indonesia dengan nilai PM2.5 sebesar 34,1 µg/m³. Pada tahun 2024, Jakarta tercatat memiliki nilai PM2.5 sebesar 41,7 µg/m³. Nilai tersebut menunjukkan bahwa kualitas udara Jakarta masih memerlukan perhatian karena termasuk kondisi yang dapat berdampak pada kesehatan Masyarakat.

Dalam konteks Data Mining, data historis kualitas udara dapat dimanfaatkan untuk dua kebutuhan. Pertama, data dapat digunakan untuk memprediksi kategori kualitas udara berdasarkan nilai polutan yang dimasukkan. Kedua, data dapat digunakan untuk menemukan kelompok atau pola kualitas udara berdasarkan kemiripan karakteristik polutan. Kedua

kebutuhan tersebut sesuai dengan metode classification dan clustering.

Penelitian ini menggunakan framework CRISP-DM karena memiliki tahapan sistematis mulai dari pemahaman masalah hingga deployment aplikasi. Model classification menggunakan Random Forest Classifier, sedangkan model clustering menggunakan K-Means Clustering. Hasil akhir penelitian diwujudkan dalam aplikasi web berbasis Streamlit sehingga pengguna dapat melakukan prediksi dan melihat hasil analisis secara interaktif.

Rumusan masalah penelitian ini meliputi: bagaimana karakteristik kualitas udara Jakarta berdasarkan parameter polutan; bagaimana menerapkan Random Forest untuk memprediksi kategori kualitas udara; dan bagaimana menerapkan K-Means untuk mengelompokkan pola kualitas udara. Tujuan penelitian adalah melakukan analisis data, menyiapkan data, membangun model classification, membangun model clustering, dan mengimplementasikan model ke aplikasi web.

Rangking	Kota	2023	2024	2023	2022	2021	2020	2019	2018	2017
1	South Tangerang, Indonesia	55.0	65.1	71.7	--	--	--	--	--	--
2	Cikande, Indonesia	45	52.2	--	--	--	--	--	--	--
3	Cikarang, Indonesia	66.6	52.9	53	62.6	--	--	--	--	--
4	Degok, Indonesia	62.6	58.3	57.8	57.7	65.6	--	--	--	--
5	Buduran, Indonesia	46.6	54.4	--	--	--	--	--	--	--
6	Gresik, Indonesia	46.6	--	--	--	--	--	--	--	--
7	Tangerang, Indonesia	59.2	55.6	54.1	56.5	--	--	--	--	--
8	Serpong, Indonesia	55.4	45.4	53.2	56	--	--	--	--	--
9	Bandung, Indonesia	54.6	48	56.6	54.1	51.4	51.2	--	--	--
10	Jakarta, Indonesia	54.1	47	44.8	54.1	59.3	54.6	48.4	46.3	50.7
11	Bandar Lampung, Indonesia	53.6	54	56.5	57	57.6	--	--	--	--

Gbr. 1 Data pendukung kualitas udara Jakarta setiap tahun berdasarkan IQAir.

Gbr. 1 digunakan sebagai penguat latar belakang bahwa kualitas udara Jakarta menjadi isu nyata yang relevan untuk dianalisis. Data tersebut menunjukkan bahwa kualitas udara dapat berubah antar tahun sehingga pendekatan berbasis data historis diperlukan untuk memahami pola dan memprediksi kategori kualitas udara.

II. TINJAUAN PUSTAKA

A. Data Mining

Data Mining merupakan proses ekstraksi informasi, pola, hubungan, dan pengetahuan yang tersembunyi dari sekumpulan data berukuran besar menggunakan kombinasi teknik statistik, kecerdasan buatan, machine learning, serta pengelolaan basis data. Tujuan utama Data Mining adalah mengubah data mentah yang sebelumnya hanya berfungsi sebagai arsip menjadi informasi yang bernilai dan dapat digunakan untuk mendukung

proses pengambilan keputusan. Seiring berkembangnya teknologi informasi dan meningkatnya volume data yang dihasilkan setiap hari, Data Mining menjadi salah satu bidang yang sangat penting dalam berbagai sektor, seperti kesehatan, pendidikan, keuangan, transportasi, pemasaran, hingga lingkungan.

Secara umum, proses Data Mining mencakup beberapa tahapan, mulai dari pengumpulan data, pembersihan data, transformasi data, pembangunan model, evaluasi hasil, hingga implementasi model. Hasil dari proses tersebut dapat berupa prediksi, klasifikasi, segmentasi, maupun identifikasi pola tertentu yang sebelumnya sulit ditemukan secara manual. Dengan memanfaatkan Data Mining, organisasi dapat memperoleh wawasan yang lebih mendalam mengenai kondisi yang sedang terjadi serta memprediksi kemungkinan yang akan terjadi di masa mendatang.

Beberapa metode yang umum digunakan dalam Data Mining antara lain classification, regression, clustering, association rule mining, dan anomaly detection. Masing-masing metode memiliki tujuan yang berbeda sesuai dengan karakteristik permasalahan yang dihadapi. Pada penelitian ini digunakan metode classification dan clustering. Metode classification diterapkan untuk memprediksi kategori kualitas udara berdasarkan parameter polutan yang tersedia, sedangkan clustering digunakan untuk mengelompokkan data kualitas udara berdasarkan tingkat kemiripan karakteristik polutan. Kombinasi kedua metode tersebut diharapkan mampu memberikan hasil analisis yang lebih komprehensif, yaitu tidak hanya menghasilkan prediksi kategori kualitas udara, tetapi juga memberikan pemahaman mengenai pola-pola kualitas udara yang terbentuk dari data historis Jakarta.

B. CRISP-DM

CRISP-DM (*Cross Industry Standard Process for Data Mining*) merupakan metodologi standar yang umum digunakan dalam Project Data Mining dan Business Intelligence. Metodologi ini menyediakan kerangka kerja yang sistematis, terstruktur, dan fleksibel dalam mengelola proses analisis data, mulai dari pemahaman masalah bisnis hingga implementasi hasil analisis (Schröer, Kruse, and Gómez 2021). Keunggulan utama CRISP-DM terletak pada pendekatannya yang iteratif, di mana setiap tahapan dapat diulang dan disesuaikan sesuai dengan kebutuhan Project. Hal ini memungkinkan proses analisis menjadi lebih adaptif terhadap perubahan kondisi data

maupun kebutuhan bisnis. Framework ini dipilih karena alurnya sistematis dan mudah diterapkan pada proyek akademik.

. Data preparation digunakan untuk membersihkan dan menyiapkan data. Modeling digunakan untuk membangun Random Forest dan K-Means. Evaluation digunakan untuk menilai performa model, sedangkan deployment digunakan untuk membuat aplikasi Streamlit. CRISP-DM terdiri dari enam tahapan utama yang saling terintegrasi, yaitu:

1. Business Understanding

Tahap Business Understanding merupakan tahap awal yang bertujuan untuk memahami permasalahan yang akan diselesaikan serta menentukan tujuan penelitian. Pada penelitian ini, permasalahan utama yang diangkat adalah kondisi kualitas udara Jakarta yang cenderung mengalami penurunan akibat tingginya aktivitas transportasi, industri, pembangunan, dan kepadatan penduduk. Polusi udara yang tinggi dapat berdampak langsung terhadap kesehatan masyarakat sehingga diperlukan upaya pemantauan dan analisis kualitas udara secara lebih efektif.

Tujuan utama penelitian ini adalah: Menganalisis karakteristik dataset kualitas udara Jakarta berdasarkan parameter polutan yang tersedia; Melakukan preprocessing data agar dataset siap digunakan dalam proses Data Mining; Membangun model classification untuk memprediksi kategori kualitas udara Jakarta, seperti Baik, Sedang, Tidak Sehat, dan Sangat Tidak Sehat; Membangun model clustering untuk mengelompokkan data kualitas udara Jakarta berdasarkan kemiripan pola polutan; dan Mengimplementasikan model terbaik ke dalam aplikasi web berbasis Streamlit sehingga pengguna dapat melakukan prediksi dan melihat hasil analisis secara interaktif.

Melalui tahap ini, kebutuhan penelitian dapat dirumuskan secara jelas sehingga proses Data Mining dapat berjalan sesuai tujuan yang telah ditetapkan.

2. Data Understanding

Tahap Data Understanding bertujuan untuk memahami karakteristik dataset yang digunakan dalam penelitian. Dataset yang digunakan merupakan hasil penggabungan beberapa sumber data kualitas udara Jakarta yang diperoleh dari Kaggle dan Data.go.id. Dataset tersebut berisi informasi mengenai konsentrasi berbagai polutan udara

seperti PM2.5, PM10, SO₂, CO, O₃, dan NO₂ yang digunakan sebagai fitur utama dalam analisis.

Pada tahap ini dilakukan proses eksplorasi data (Exploratory Data Analysis/EDA) untuk mengetahui struktur data, distribusi kelas, hubungan antar variabel, serta potensi permasalahan yang terdapat pada dataset. Hasil eksplorasi menunjukkan bahwa distribusi kategori kualitas udara tidak seimbang, di mana kategori SEDANG memiliki jumlah data paling banyak sedangkan kategori SANGAT TIDAK SEHAT memiliki jumlah data paling sedikit. Selain itu, beberapa parameter polutan memiliki distribusi yang berbeda-beda dan menunjukkan adanya korelasi antar fitur.

Pemahaman terhadap karakteristik data ini menjadi dasar dalam menentukan teknik persiapan data dan metode analisis yang sesuai.

3. Data Preparation

Tahap Data Preparation merupakan proses menyiapkan data agar siap digunakan dalam pemodelan. Kualitas data yang baik sangat menentukan performa model yang akan dibangun. Oleh karena itu, dilakukan berbagai proses pembersihan dan transformasi data sebelum memasuki tahap modelling.

Pada penelitian ini, tahapan Data Preparation meliputi: Penghapusan data duplikat untuk menghindari redundansi data; Mapping kategori kualitas udara ke dalam bentuk numerik agar dapat diproses oleh algoritma Machine Learning; Pembagian data menjadi data latih (training set) dan data uji (testing set) dengan rasio 80:20 menggunakan metode stratified split; Penerapan RobustScaler untuk menyesuaikan skala antar fitur numerik; Penerapan *Synthetic Minority Oversampling Technique* (SMOTE) untuk mengatasi ketidakseimbangan kelas pada data latih; dan Persiapan data khusus untuk proses clustering dengan menghilangkan atribut target.

Melalui tahap ini diperoleh dataset yang lebih bersih, konsisten, dan siap digunakan untuk membangun model klasifikasi maupun clustering.

4. Modeling

Tahap Modeling merupakan proses pembangunan model Data Mining yang digunakan untuk menghasilkan informasi dan pola yang bermanfaat. Pada penelitian ini digunakan dua pendekatan berbeda, yaitu klasifikasi (classification) dan clustering.

Untuk proses klasifikasi digunakan algoritma Random Forest Classifier. Algoritma ini dipilih karena mampu menangani data numerik dengan baik, relatif stabil terhadap variasi data, serta memiliki kemampuan untuk mengurangi risiko overfitting melalui mekanisme ensemble learning. Selain itu, dilakukan optimasi parameter menggunakan RandomizedSearchCV untuk memperoleh kombinasi hyperparameter terbaik.

Sementara itu, proses clustering menggunakan algoritma K-Means Clustering yang bertujuan untuk menemukan pola pengelompokan kualitas udara berdasarkan kemiripan karakteristik polutan. Penentuan jumlah cluster dilakukan dengan mempertimbangkan hasil Elbow Method dan interpretasi terhadap karakteristik data. Model akhir menghasilkan empat kelompok kualitas udara yang diinterpretasikan sebagai polusi rendah, moderat, tinggi, dan ekstrem.

5. Evaluation

Tahap Evaluation dilakukan untuk mengukur performa model yang telah dibangun dan memastikan bahwa hasil yang diperoleh sesuai dengan tujuan penelitian. Evaluasi model klasifikasi dilakukan menggunakan metrik Accuracy, Precision Macro, Recall Macro, F1 Macro, serta Confusion Matrix. Penggunaan F1 Macro dianggap penting karena dataset memiliki distribusi kelas yang tidak seimbang sehingga performa pada seluruh kategori dapat dievaluasi secara lebih adil.

Hasil evaluasi menunjukkan bahwa model Random Forest memperoleh nilai Accuracy sebesar 98,20% dan F1 Macro sebesar 96,85%. Selisih nilai F1 Macro antara data latih dan data uji hanya sebesar 0,0303 sehingga model tidak terindikasi mengalami overfitting.

Untuk model clustering, evaluasi dilakukan menggunakan metrik Silhouette Score dan Davies-Bouldin Index. Hasil evaluasi menunjukkan bahwa model K-Means mampu menghasilkan empat cluster yang cukup seimbang dan dapat digunakan untuk memberikan insight tambahan mengenai pola kualitas udara Jakarta.

6. Deployment

Tahap Deployment merupakan tahap akhir dalam metodologi CRISP-DM, yaitu proses implementasi hasil analisis agar dapat dimanfaatkan oleh pengguna. Pada penelitian ini, model yang telah dibangun

diimplementasikan ke dalam aplikasi web berbasis Streamlit sehingga pengguna dapat melakukan prediksi kualitas udara dan analisis cluster secara interaktif.

Aplikasi menerima input berupa nilai PM2.5, PM10, SO₂, CO, O₃, dan NO₂, kemudian menghasilkan prediksi kategori kualitas udara menggunakan model Random Forest serta informasi cluster menggunakan model K-Means. Selain itu, aplikasi juga menyediakan visualisasi data dan informasi pendukung yang membantu pengguna memahami kondisi kualitas udara Jakarta.

Implementasi dalam bentuk aplikasi web memungkinkan hasil penelitian tidak hanya berhenti pada tahap analisis, tetapi juga dapat digunakan sebagai alat bantu pengambilan keputusan dan media edukasi mengenai kualitas udara secara lebih praktis dan mudah diakses.

C. Kualitas Udara dan Polutan

Kualitas udara merupakan kondisi udara pada suatu wilayah yang diukur berdasarkan konsentrasi berbagai zat pencemar atau polutan yang terdapat di atmosfer. Kualitas udara yang baik sangat penting karena berhubungan langsung dengan kesehatan manusia, produktivitas masyarakat, serta keberlanjutan lingkungan. Sebaliknya, kualitas udara yang buruk dapat meningkatkan risiko berbagai penyakit, terutama gangguan sistem pernapasan dan kardiovaskular. Oleh karena itu, pemantauan kualitas udara menjadi salah satu aspek penting dalam pengelolaan lingkungan perkotaan.

Beberapa parameter polutan yang umum digunakan untuk mengukur kualitas udara adalah PM2.5, PM10, SO₂, CO, O₃, dan NO₂. PM2.5 merupakan partikel dengan diameter kurang dari 2,5 mikrometer yang dapat masuk hingga ke paru-paru dan aliran darah manusia. PM10 adalah partikel dengan ukuran lebih besar, tetapi tetap dapat menimbulkan gangguan kesehatan apabila terhirup dalam jumlah tinggi. Selain partikel, terdapat pula polutan berbentuk gas seperti sulfur dioksida (SO₂), karbon monoksida (CO), ozon (O₃), dan nitrogen dioksida (NO₂) yang sebagian besar berasal dari aktivitas industri, transportasi, dan pembakaran bahan bakar fosil.

Dalam penelitian ini, seluruh parameter polutan tersebut digunakan sebagai fitur utama untuk membangun model Data Mining. Setiap parameter memiliki karakteristik dan dampak yang berbeda terhadap kualitas udara. Kombinasi seluruh parameter tersebut memberikan gambaran yang lebih lengkap mengenai kondisi udara suatu wilayah dibandingkan jika hanya

menggunakan satu indikator saja. Kategori kualitas udara yang digunakan pada penelitian ini terdiri dari Baik, Sedang, Tidak Sehat, dan Sangat Tidak Sehat. Kategori tersebut digunakan sebagai target pada proses classification, sedangkan nilai polutan digunakan sebagai dasar pembentukan kelompok pada proses clustering. Dengan demikian, analisis yang dilakukan dapat menggambarkan kondisi kualitas udara Jakarta secara lebih komprehensif dan objektif.

D. Random Forest Classifier

Random Forest merupakan salah satu algoritma Machine Learning yang termasuk dalam kategori ensemble learning. Algoritma ini bekerja dengan membangun sejumlah pohon keputusan (decision tree) secara acak, kemudian menggabungkan hasil prediksi dari seluruh pohon tersebut untuk menghasilkan keputusan akhir. Pendekatan ini membuat Random Forest memiliki tingkat akurasi yang tinggi serta lebih stabil dibandingkan penggunaan satu pohon keputusan Tunggal.

Prinsip utama Random Forest adalah memanfaatkan teknik bagging (bootstrap aggregating), yaitu proses pelatihan banyak model menggunakan sampel data yang berbeda-beda. Setiap pohon keputusan dibangun menggunakan sebagian data yang dipilih secara acak dan hanya mempertimbangkan sebagian fitur pada setiap proses pemisahan node. Hasil prediksi akhir diperoleh melalui mekanisme voting mayoritas pada kasus klasifikasi. Dengan cara tersebut, risiko overfitting dapat dikurangi karena model tidak bergantung pada satu struktur pohon tertentu.

Salah satu keunggulan Random Forest adalah kemampuannya dalam menangani data numerik maupun kategorikal serta ketahanannya terhadap noise dan outlier. Selain itu, algoritma ini mampu menghasilkan informasi feature importance yang menunjukkan tingkat kontribusi masing-masing variabel terhadap hasil prediksi. Informasi tersebut sangat berguna untuk memahami faktor-faktor yang paling berpengaruh terhadap kualitas udara.

Pada penelitian ini, Random Forest digunakan sebagai model utama untuk memprediksi kategori kualitas udara Jakarta berdasarkan nilai PM2.5, PM10, SO₂, CO, O₃, dan NO₂. Untuk memperoleh performa yang optimal, dilakukan proses tuning hyperparameter menggunakan RandomizedSearchCV. Evaluasi model dilakukan menggunakan accuracy, precision macro, recall macro, dan F1 macro. Hasil evaluasi

menunjukkan bahwa Random Forest mampu menghasilkan performa yang sangat baik sehingga layak digunakan sebagai model prediksi kualitas udara dalam aplikasi yang dikembangkan.

E. K-Means Clustering

K-Means Clustering merupakan salah satu algoritma unsupervised learning yang digunakan untuk mengelompokkan data berdasarkan tingkat kemiripan karakteristiknya. Berbeda dengan metode classification yang memerlukan label target, K-Means bekerja tanpa informasi kategori sehingga kelompok data dibentuk secara otomatis berdasarkan pola yang ditemukan pada dataset. Algoritma ini termasuk salah satu metode clustering yang paling populer karena sederhana, efisien, dan mudah diimplementasikan.

Proses kerja K-Means dimulai dengan menentukan jumlah cluster yang akan dibentuk. Selanjutnya algoritma memilih centroid awal secara acak, kemudian menghitung jarak setiap data terhadap centroid tersebut. Setiap data akan ditempatkan pada cluster dengan jarak terdekat. Setelah seluruh data dikelompokkan, centroid baru dihitung berdasarkan rata-rata anggota pada masing-masing cluster. Proses ini diulang hingga posisi centroid relatif stabil atau tidak mengalami perubahan yang signifikan.

Pada penelitian ini, K-Means digunakan untuk mengelompokkan data kualitas udara Jakarta berdasarkan parameter PM2.5, PM10, SO₂, CO, O₃, dan NO₂. Tujuan utama penggunaan clustering adalah menemukan pola kualitas udara yang mungkin tidak terlihat melalui metode klasifikasi. Sebelum proses clustering dilakukan, seluruh fitur numerik dinormalisasi menggunakan RobustScaler agar perbedaan rentang nilai antar fitur tidak memengaruhi hasil pengelompokan.

Penentuan jumlah cluster dilakukan menggunakan Elbow Method yang bertujuan menemukan titik optimal berdasarkan perubahan nilai inertia. Hasil analisis menunjukkan bahwa empat cluster memberikan keseimbangan antara kualitas pengelompokan dan kemudahan interpretasi. Keempat cluster tersebut kemudian diinterpretasikan sebagai polusi rendah, polusi moderat, polusi tinggi, dan polusi ekstrem. Hasil clustering ini digunakan sebagai pelengkap analisis sehingga pengguna tidak hanya memperoleh hasil prediksi kategori kualitas udara, tetapi juga memperoleh informasi mengenai pola kemiripan data kualitas udara Jakarta.

F. Evaluasi Model dan Streamlit

Evaluasi model merupakan tahap penting dalam penelitian Data Mining karena digunakan untuk mengukur sejauh mana model mampu menjalankan tugas yang diberikan secara akurat dan konsisten. Evaluasi dilakukan terhadap model classification maupun clustering dengan menggunakan metrik yang sesuai dengan karakteristik masing-masing metode. Hasil evaluasi menjadi dasar dalam menentukan apakah model layak digunakan pada tahap deployment.

Pada model classification menggunakan Random Forest, evaluasi dilakukan menggunakan Accuracy, Precision Macro, Recall Macro, F1 Macro, dan Confusion Matrix. Accuracy digunakan untuk mengukur persentase prediksi yang benar terhadap seluruh data uji. Namun karena distribusi kategori kualitas udara tidak seimbang, evaluasi tidak hanya bergantung pada accuracy. Precision Macro, Recall Macro, dan F1 Macro digunakan untuk memberikan gambaran performa model pada seluruh kategori secara lebih adil. Confusion Matrix digunakan untuk melihat distribusi prediksi benar dan salah pada setiap kategori kualitas udara.

Selain itu, dilakukan pemeriksaan overfitting dengan membandingkan nilai F1 Macro pada data latih dan data uji. Selisih yang relatif kecil menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dan tidak hanya menghafal pola pada data pelatihan. Hasil evaluasi menunjukkan bahwa Random Forest memiliki performa yang sangat baik sehingga layak digunakan sebagai model utama prediksi kualitas udara.

Untuk model clustering menggunakan K-Means, evaluasi dilakukan menggunakan Silhouette Score dan Davies-Bouldin Index. Kedua metrik tersebut digunakan untuk menilai kualitas pemisahan cluster dan tingkat kemiripan antar anggota cluster. Selain evaluasi numerik, dilakukan pula interpretasi karakteristik cluster berdasarkan rata-rata nilai polutan agar hasil clustering lebih mudah dipahami.

Tahap deployment dilakukan menggunakan Streamlit karena framework ini mampu mengubah model Data Science menjadi aplikasi web interaktif dengan relatif cepat. Streamlit menyediakan berbagai komponen visual seperti form input, tabel, grafik, dan panel hasil prediksi. Melalui aplikasi yang dikembangkan, pengguna dapat memasukkan nilai PM2.5, PM10, SO₂, CO, O₃, dan NO₂ untuk memperoleh hasil prediksi kategori kualitas udara beserta informasi cluster secara langsung.



Gbr. 2 Alur tahapan penelitian menggunakan framework CRISP-DM.

III. METODOLOGI

A. Desain Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan metode Data Mining untuk menganalisis dan memprediksi kualitas udara Jakarta berdasarkan data historis parameter polutan. Pendekatan kuantitatif dipilih karena penelitian berfokus pada pengolahan data numerik dalam jumlah besar untuk menghasilkan pola, informasi, dan prediksi yang dapat diukur secara objektif. Selain itu, penelitian ini juga menggabungkan pendekatan supervised learning dan unsupervised learning sehingga mampu memberikan hasil analisis yang lebih lengkap.

Framework yang digunakan dalam penelitian ini adalah Cross Industry Standard Process for Data Mining (CRISP-DM). Pemilihan CRISP-DM didasarkan pada kemampuannya dalam menyediakan tahapan kerja yang sistematis dan terstruktur mulai dari identifikasi permasalahan hingga implementasi model ke dalam aplikasi. Melalui pendekatan ini, setiap tahapan penelitian dapat dilakukan secara terukur dan terdokumentasi dengan baik sehingga memudahkan proses evaluasi serta pengembangan lebih lanjut.

Alur penelitian dimulai dari identifikasi permasalahan kualitas udara Jakarta yang kemudian dilanjutkan dengan pengumpulan data dari berbagai sumber. Setelah data diperoleh, dilakukan proses eksplorasi untuk memahami karakteristik dataset, distribusi kategori kualitas udara, serta hubungan antar parameter polutan. Tahap berikutnya adalah Data Preparation yang meliputi pembersihan data, transformasi data, normalisasi fitur, serta penanganan ketidakseimbangan kelas menggunakan SMOTE.

Pada tahap Modeling digunakan dua pendekatan berbeda. Pendekatan pertama adalah classification menggunakan Random Forest Classifier untuk memprediksi kategori kualitas udara. Pendekatan kedua adalah clustering menggunakan K-Means untuk mengidentifikasi pola kelompok kualitas udara berdasarkan kemiripan karakteristik polutan. Selanjutnya dilakukan evaluasi model menggunakan berbagai metrik yang sesuai dengan tujuan masing-masing metode. Tahap akhir berupa deployment model ke dalam aplikasi web berbasis Streamlit sehingga hasil penelitian dapat dimanfaatkan secara langsung oleh pengguna. Dengan desain penelitian tersebut, diharapkan diperoleh model yang tidak hanya akurat dalam melakukan prediksi, tetapi juga mampu memberikan insight tambahan mengenai pola kualitas udara Jakarta.

B. Dataset Penelitian

Dataset yang digunakan dalam penelitian ini berasal dari beberapa sumber data terbuka yang menyediakan informasi mengenai kualitas udara Jakarta. Sumber utama data diperoleh dari platform Kaggle dan portal data pemerintah Indonesia melalui Data.go.id. Penggunaan beberapa sumber data dilakukan untuk memperoleh cakupan data yang lebih luas serta meningkatkan representativitas kondisi kualitas udara yang dianalisis.

Dataset yang dikumpulkan memuat berbagai parameter polutan yang umum digunakan dalam pengukuran kualitas udara, yaitu PM2.5, PM10, SO₂, CO, O₃, dan NO₂. Parameter tersebut dipilih karena memiliki peran penting dalam menentukan tingkat pencemaran udara dan digunakan secara luas dalam sistem pemantauan kualitas udara di berbagai negara. Selain itu, dataset juga memuat informasi kategori kualitas udara yang digunakan sebagai target pada proses classification.

Sebelum digunakan dalam proses analisis, seluruh dataset dari berbagai sumber digabungkan menjadi satu dataset terpadu. Proses integrasi dilakukan dengan menyesuaikan struktur data, nama atribut, serta format penyimpanan agar seluruh data dapat diproses secara konsisten. Setelah proses penggabungan selesai, dilakukan pemeriksaan kualitas data untuk mengidentifikasi adanya data duplikat, inkonsistensi, maupun nilai yang tidak sesuai.

Hasil proses pembersihan menghasilkan sebanyak 3.892 data yang siap digunakan dalam penelitian. Dataset tersebut kemudian dibagi menjadi data latih dan data uji dengan rasio

80:20 menggunakan metode stratified split untuk mempertahankan proporsi kategori kualitas udara pada kedua kelompok data. Penggunaan dataset yang berasal dari berbagai sumber memberikan keuntungan berupa keragaman data yang lebih tinggi sehingga model yang dibangun memiliki peluang lebih baik dalam mengenali pola kualitas udara Jakarta secara menyeluruh. Dengan demikian, hasil analisis yang diperoleh diharapkan lebih representatif terhadap kondisi kualitas udara yang sebenarnya.

TABEL I
INFORMASI DATASET

Komponen	Keterangan
Nama dataset	final_dataset.csv
Jumlah data awal	5831
Jumlah data bersih	5455
Jumlah kolom awal	10
Fitur utama	PM2.5, PM10, SO ₂ , CO, O ₃ , NO ₂
Target classification	kategori
Metode	Classification dan Clustering
Framework	CRISP-DM

TABEL II
SUMBER DATASET YANG DIGUNAKAN

No.	Sumber Dataset	Platform	Keterangan
1.	Indeks Pencemaran Udara DKI	Kaggle	Data pencemaran udara DKI Jakarta
2.	Air Quality Index in Jakarta 2010-2021	Kaggle	Data kualitas udara Jakarta
3.	Data ISPU Provinsi DKI Jakarta	Data.go.id	Data lokal ISPU DKI Jakarta
4.	ISPU Tahun 2013	Data.go.id	Data ISPU tahun 2013
5.	ISPU Tahun 2012	Data.go.id	Data ISPU tahun 2012
6.	ISPU Tahun 2011	Data.go.id	Data ISPU tahun 2011
7.	ISPU Tahun 2010	Data.go.id	Data ISPU tahun 2010

C. Tahapan Data Preparation

Tahap Data Preparation merupakan salah satu tahapan paling penting dalam proses Data Mining karena kualitas data yang digunakan akan sangat memengaruhi kualitas model yang dihasilkan. Data yang berasal dari berbagai sumber umumnya masih mengandung permasalahan seperti duplikasi data,

ketidakkonsistenan format, ketidakseimbangan distribusi kelas, maupun perbedaan skala antar atribut. Oleh karena itu, sebelum dilakukan proses pemodelan, dataset perlu dipersiapkan terlebih dahulu agar memiliki kualitas yang baik dan siap digunakan oleh algoritma Machine Learning.

Pada penelitian ini, proses Data Preparation diawali dengan penggabungan beberapa dataset kualitas udara Jakarta yang berasal dari Kaggle dan Data.go.id. Setelah proses integrasi selesai dilakukan, tahap berikutnya adalah pemeriksaan kualitas data untuk mengidentifikasi kemungkinan adanya data duplikat. Data yang teridentifikasi memiliki isi yang sama kemudian dihapus agar tidak menimbulkan bias pada proses pelatihan model. Hasil pembersihan menghasilkan dataset yang lebih konsisten dan representatif terhadap kondisi kualitas udara Jakarta.

Selanjutnya dilakukan proses transformasi target kategori kualitas udara ke dalam bentuk numerik. Kategori BAIK dipetakan menjadi nilai 0, SEDANG menjadi 1, TIDAK SEHAT menjadi 2, dan SANGAT TIDAK SEHAT menjadi 3. Transformasi ini diperlukan karena algoritma Machine Learning bekerja lebih efektif ketika target direpresentasikan dalam bentuk numerik. Setelah itu, dataset dibagi menjadi data latih dan data uji menggunakan rasio 80:20 dengan metode stratified split sehingga proporsi setiap kategori tetap terjaga pada kedua kelompok data.

Tahap berikutnya adalah normalisasi fitur menggunakan RobustScaler. Metode ini dipilih karena lebih tahan terhadap pengaruh outlier dibandingkan teknik scaling lainnya. Selain itu, dilakukan penerapan Synthetic Minority Oversampling Technique (SMOTE) pada data latih untuk mengatasi ketidakseimbangan distribusi kategori kualitas udara. Proses oversampling membantu model memperoleh jumlah contoh yang lebih seimbang pada setiap kategori sehingga meningkatkan kemampuan model dalam mengenali kelas minoritas. Dataset yang telah melalui seluruh tahapan tersebut kemudian digunakan sebagai masukan pada proses classification dan clustering.

TABEL III
TAHAPAN DATA PREPARATION

No.	Tahapan	Tujuan
1.	Menghapus duplikasi	Menghindari data berulang
2.	Mapping kategori	Mengubah label menjadi angka

3.	Train-test split	Membagi data latih dan uji
4.	RobustScaler	Menyamakan skala fitur numerik
5.	SMOTE	Mengatasi ketidakseimbangan kelas
6.	Data clustering	Menyiapkan data tanpa target

D. Tahapan Modeling

Tahap Modeling merupakan proses pembangunan model Data Mining yang bertujuan menghasilkan informasi, pola, dan prediksi berdasarkan data yang telah dipersiapkan sebelumnya. Pada penelitian ini digunakan dua pendekatan berbeda, yaitu supervised learning melalui Random Forest Classifier dan unsupervised learning melalui K-Means Clustering. Penggunaan kedua metode tersebut dilakukan agar penelitian tidak hanya mampu menghasilkan prediksi kategori kualitas udara, tetapi juga dapat mengidentifikasi pola pengelompokan data berdasarkan karakteristik polutan.

Model pertama yang dibangun adalah Random Forest Classifier. Algoritma ini dipilih karena memiliki kemampuan yang baik dalam menangani data numerik, relatif stabil terhadap variasi data, serta mampu mengurangi risiko overfitting melalui pendekatan ensemble learning. Random Forest bekerja dengan membangun sejumlah pohon keputusan yang dilatih menggunakan sampel data berbeda. Hasil prediksi dari seluruh pohon kemudian digabungkan menggunakan mekanisme voting untuk menghasilkan keputusan akhir. Pendekatan ini membuat model lebih robust dibandingkan penggunaan satu pohon keputusan Tunggal.

Untuk memperoleh performa terbaik, dilakukan proses tuning hyperparameter menggunakan RandomizedSearchCV. Parameter yang diuji meliputi jumlah pohon (`n_estimators`), kriteria pemisahan node (`criterion`), kedalaman maksimum pohon (`max_depth`), dan jumlah minimum sampel untuk melakukan pemisahan (`min_samples_split`). Proses tuning dilakukan menggunakan validasi silang lima lipatan sehingga kombinasi parameter terbaik dapat dipilih secara objektif berdasarkan performa model.

Selain classification, penelitian ini juga membangun model clustering menggunakan algoritma K-Means. Sebelum menentukan model akhir, dilakukan eksperimen menggunakan beberapa jumlah cluster yang berbeda. Elbow Method digunakan sebagai pendekatan awal untuk menentukan jumlah cluster yang paling sesuai berdasarkan perubahan nilai inertia. Setelah dilakukan evaluasi dan interpretasi hasil, dipilih empat cluster sebagai model akhir karena memberikan keseimbangan

antara kualitas pengelompokan dan kemudahan interpretasi. Hasil clustering kemudian digunakan untuk memberikan informasi tambahan mengenai pola kualitas udara Jakarta berdasarkan kemiripan karakteristik polutan yang dimiliki setiap data.

TABEL IV
HYPERPARAMETER RANDOM FOREST YANG DIUJI


Parameter	Nilai yang Diuji
n_estimators	50, 100, 150, 200
criterion	gini, entropy
max_depth	None, 10, 15, 20
min_samples_split	2, 5, 10
Metode tuning	RandomizedSearchCV
Cross-validation	5-fold

IV. HASIL DAN PEMBAHASAN

A. Hasil Data Understanding

Tahap data understanding dilakukan untuk memahami struktur, kualitas, dan pola awal dataset. Pemeriksaan awal meliputi tipe data, statistik deskriptif, missing value, duplikasi, distribusi kategori, distribusi stasiun, serta visualisasi parameter polutan.

Hasil eksplorasi menunjukkan bahwa data memiliki karakteristik yang tidak seimbang pada target kategori. Kategori SEDANG merupakan kategori paling dominan, sedangkan kategori SANGAT TIDAK SEHAT memiliki jumlah yang paling kecil. Ketidakseimbangan ini berpotensi membuat model lebih mudah mempelajari kelas mayoritas dibandingkan kelas minoritas.




Gbr. 3. Distribusi jumlah data berdasarkan kategori kualitas udara.

Gbr. 3 menunjukkan bahwa kategori kualitas udara tidak tersebar merata. Temuan ini menjadi dasar penerapan SMOTE pada tahap data preparation karena model classification perlu belajar dari setiap kategori secara lebih seimbang.


Ketidakseimbangan kategori juga memengaruhi cara pembacaan metrik evaluasi. Jika model hanya mengikuti kelas mayoritas, nilai accuracy dapat terlihat tinggi tetapi kemampuan mengenali kelas minoritas menjadi rendah. Oleh sebab itu, penelitian ini tidak hanya menggunakan accuracy, tetapi juga precision macro, recall macro, dan F1 macro.

Distribusi kategori yang tidak merata menunjukkan bahwa kualitas udara historis Jakarta lebih sering berada pada kategori tertentu. Informasi tersebut penting untuk menjelaskan konteks data sebelum dilakukan proses pemodelan karena model akan belajar dari pola historis yang tersedia di dataset.



Gbr. 4. Distribusi nilai parameter polutan pada dataset kualitas udara Jakarta.


Gbr. 4 menunjukkan bahwa setiap parameter polutan memiliki pola distribusi yang berbeda. Beberapa fitur memiliki sebaran yang cenderung miring sehingga scaling diperlukan sebelum data digunakan pada model classification dan clustering.



Gbr. 5. Matriks korelasi antar parameter polutan kualitas udara.

Gbr. 5 memperlihatkan hubungan antar parameter polutan. Korelasi ini digunakan untuk memahami keterkaitan fitur sebelum modeling, meskipun seluruh fitur tetap digunakan

karena masing-masing polutan merepresentasikan kondisi pencemaran yang berbeda.




Gbr. 6. Sebaran nilai polutan berdasarkan kategori kualitas udara.

Gbr. 6 menunjukkan bahwa nilai polutan cenderung berbeda pada tiap kategori kualitas udara. Kategori yang lebih buruk umumnya memiliki nilai polutan yang lebih tinggi. Hal ini mendukung relevansi fitur polutan sebagai variabel prediktor dalam classification.

B. Hasil Data Preparation

Setelah data dipahami, dilakukan data preparation. Penghapusan duplikasi menghasilkan 3.892 data bersih. Kategori kualitas udara dipetakan menjadi angka, yaitu BAIK = 0, SEDANG = 1, TIDAK SEHAT = 2, dan SANGAT TIDAK SEHAT = 3. Pemetaan ini diperlukan agar model dapat memproses target secara numerik.

Data kemudian dibagi menjadi data latih dan data uji dengan rasio 80:20. Pembagian dilakukan secara stratified agar proporsi kategori pada data latih dan data uji tetap menyerupai data keseluruhan. Untuk mengurangi dampak ketidakseimbangan kelas, SMOTE diterapkan pada data latih.



Gbr. 7. Perbandingan distribusi kelas sebelum dan sesudah penerapan SMOTE.

Gbr. 7 menunjukkan bahwa setelah SMOTE, jumlah data pada setiap kategori di data latih menjadi lebih seimbang. Penyeimbangan ini membantu Random Forest agar tidak terlalu memihak pada kelas mayoritas.

SMOTE diterapkan hanya pada data latih agar data uji tetap merepresentasikan kondisi asli. Hal ini penting untuk menghindari evaluasi yang terlalu optimis. Dengan demikian, performa model tetap diuji pada data yang tidak dimodifikasi oleh proses oversampling.

Selain SMOTE, scaling menggunakan RobustScaler dilakukan untuk menstabilkan skala fitur. Scaling diperlukan karena parameter polutan memiliki rentang nilai berbeda. Proses ini juga membantu clustering karena K-Means menggunakan konsep jarak antar data.

C. Hasil Modeling Classification


Model classification yang digunakan adalah Random Forest Classifier. Model ini dipilih karena mampu menangani fitur numerik, relatif stabil terhadap data kompleks, dan dapat memberikan informasi feature importance. Proses tuning dilakukan menggunakan RandomizedSearchCV dengan beberapa kombinasi hyperparameter.

Model classification memiliki output berupa kategori kualitas udara, yaitu Baik, Sedang, Tidak Sehat, dan Sangat Tidak Sehat. Input model terdiri dari enam parameter polutan, yaitu PM2.5, PM10, SO2, CO, O3, dan NO2.

TABEL V
RINGKASAN EVALUASI MODEL CLASSIFICATION


Metrik	Nilai
Accuracy Test	0,9820
Precision Macro Test	0,9668
Recall Macro Test	0,9706
F1 Macro Test	0,9685
Selisih Train-Test F1 Macro	0,0303
Status	Tidak terindikasi overfitting

Berdasarkan Tabel V, model Random Forest memperoleh performa yang tinggi pada data uji. Nilai F1 Macro sebesar 0,9685 menunjukkan bahwa model memiliki keseimbangan precision dan recall yang baik pada seluruh kategori. Selisih Train-Test F1 Macro sebesar 0,0303 menunjukkan bahwa model tidak terindikasi overfitting.



Gbr. 8. Confusion matrix model Random Forest pada data uji.

Confusion matrix pada Gbr. 8 menunjukkan jumlah prediksi benar dan salah pada setiap kategori. Nilai diagonal utama menggambarkan prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Secara umum, model mampu membedakan kategori kualitas udara dengan baik.



Gbr. 9. Tingkat kepentingan parameter polutan pada model Random Forest.


Gbr. 9 menunjukkan feature importance yang digunakan untuk melihat kontribusi masing-masing parameter polutan terhadap prediksi model. Informasi ini membantu interpretasi model karena pengguna dapat mengetahui parameter yang paling berpengaruh terhadap keputusan classification.

D. Hasil Modeling Clustering

Model clustering digunakan sebagai metode pendukung untuk menemukan pola pengelompokan kualitas udara. Berbeda dengan classification, clustering tidak menggunakan target kategori dalam proses pembentukan kelompok. Data yang digunakan adalah nilai PM2.5, PM10, SO2, CO, O3, dan NO2 yang telah melalui scaling.

Eksperimen clustering dilakukan dengan membandingkan beberapa konfigurasi. Elbow Method digunakan untuk melihat pola penurunan inertia, kemudian hasil model dipertimbangkan

dengan metrik internal seperti Silhouette Score dan Davies-Bouldin Index.



Gbr. 10. Elbow Method pada model K-Means Clustering.

Gbr. 10 menunjukkan perubahan inertia pada beberapa jumlah cluster. Penurunan inertia digunakan sebagai pertimbangan awal sebelum memilih jumlah cluster final. Pada penelitian ini, model final menggunakan empat cluster agar interpretasi selaras dengan kategori kualitas udara.

Pemilihan jumlah cluster tidak hanya bergantung pada Elbow Method, tetapi juga mempertimbangkan interpretasi hasil. Pada proyek ini, empat cluster lebih mudah dikaitkan dengan tingkatan kualitas udara, yaitu polusi rendah, moderat, tinggi, dan ekstrem.


K-Means dipilih sebagai model final karena dapat digunakan pada aplikasi web untuk menentukan cluster dari input baru. Berbeda dengan beberapa metode hierarchical clustering, K-Means menyediakan mekanisme prediksi cluster yang lebih praktis untuk deployment.

TABEL VI

HASIL EVALUASI MODEL CLUSTERING


Metrik	Nilai
Algoritma	K-Means Clustering
Jumlah Cluster	4
Silhouette Score	0,2031
Davies-Bouldin Index	1,7434
Balance Score	0,9795
Imbalance Ratio	1,0210

Tabel VI menunjukkan hasil evaluasi model clustering final. Nilai Silhouette Score sebesar 0,2031 menunjukkan bahwa pemisahan cluster belum sangat kuat, tetapi masih dapat digunakan untuk analisis pola tambahan. Balance Score sebesar 0,9795 dan Imbalance Ratio sebesar 1,0210 menunjukkan bahwa distribusi cluster relatif seimbang.



Gbr. 11. Visualisasi hasil clustering menggunakan reduksi dimensi PCA.

Gbr. 11 memperlihatkan sebaran cluster dalam dua dimensi menggunakan PCA. Visualisasi ini membantu pembaca melihat bagaimana data tersebar berdasarkan hasil pengelompokan K-Means.



Gbr. 12. Karakteristik rata-rata parameter polutan pada setiap cluster.

Gbr. 12 digunakan untuk menginterpretasikan setiap cluster berdasarkan rata-rata nilai polutan. Cluster dengan rata-rata polutan rendah diinterpretasikan sebagai polusi rendah, sedangkan cluster dengan nilai lebih tinggi diinterpretasikan sebagai polusi moderat, tinggi, dan ekstrem.

Interpretasi cluster diperlukan karena clustering tidak menghasilkan label bawaan. Tanpa interpretasi, output cluster hanya berupa angka 0, 1, 2, dan 3 yang sulit dipahami pengguna. Oleh sebab itu, setiap cluster diberi label deskriptif berdasarkan karakteristik rata-rata polutan.

Hasil clustering tidak dimaksudkan untuk menggantikan kategori resmi kualitas udara, melainkan sebagai pelengkap analisis. Hasil ini membantu melihat apakah data historis memiliki pola kelompok tertentu yang dapat dijelaskan berdasarkan kemiripan nilai polutan.

TABEL VII
INTERPRETASI LABEL CLUSTER

Cluster	Interpretasi
---------	--------------

Cluster Baik	Polusi Rendah
Cluster Sedang	Polusi Moderat
Cluster Tidak Sehat	Polusi Tinggi
Cluster Sangat Tidak Sehat	Polusi Ekstrem

E. Perbandingan Classification dan Clustering

TABEL VIII
PERBANDINGAN PERAN CLASSIFICATION DAN CLUSTERING

Metode	Algoritma	Output	Fungsi
Classification	Random Forest	Kategori kualitas udara	Prediksi label kualitas udara
Clustering	K-Means	Cluster kualitas udara	Segmentasi pola polutan

Metode classification dan clustering yang digunakan dalam penelitian ini memiliki tujuan, karakteristik, serta keluaran yang berbeda. Meskipun keduanya sama-sama termasuk teknik Data Mining, pendekatan yang digunakan berbeda sehingga menghasilkan manfaat yang saling melengkapi. Oleh karena itu, penggunaan kedua metode secara bersamaan memberikan nilai tambah dibandingkan hanya menggunakan salah satu metode saja.

Classification menggunakan Random Forest Classifier merupakan pendekatan supervised learning yang memerlukan label target selama proses pelatihan. Pada penelitian ini, label yang digunakan adalah kategori kualitas udara yang terdiri atas BAIK, SEDANG, TIDAK SEHAT, dan SANGAT TIDAK SEHAT. Tujuan utama classification adalah memprediksi kategori kualitas udara berdasarkan nilai parameter polutan yang dimasukkan pengguna. Dengan demikian, hasil yang diperoleh bersifat prediktif dan dapat langsung digunakan sebagai dasar pengambilan Keputusan.

Sebaliknya, clustering menggunakan K-Means merupakan pendekatan unsupervised learning yang tidak memerlukan label target. Algoritma bekerja dengan mengelompokkan data berdasarkan tingkat kemiripan karakteristik yang dimiliki. Hasil clustering berupa kelompok-kelompok data yang memiliki pola polutan serupa. Pada penelitian ini, empat cluster yang terbentuk diinterpretasikan sebagai polusi rendah, moderat, tinggi, dan ekstrem.

Dari sisi implementasi, classification digunakan sebagai keluaran utama aplikasi karena pengguna membutuhkan informasi kategori kualitas udara secara langsung. Sementara itu, clustering berfungsi sebagai analisis pendukung yang

membantu pengguna memahami pola kualitas udara berdasarkan data historis. Dengan kata lain, *classification* menjawab pertanyaan “termasuk kategori apa kualitas udara saat ini?”, sedangkan *clustering* membantu menjawab pertanyaan “kelompok kualitas udara seperti apa yang memiliki karakteristik serupa?”. Kombinasi keduanya menghasilkan analisis yang lebih komprehensif dan memperkaya informasi yang dapat diperoleh dari dataset kualitas udara Jakarta.

F. Pembahasan Evaluasi Model

Hasil evaluasi *classification* menunjukkan bahwa Random Forest mampu memberikan performa yang sangat baik pada data uji. Nilai *accuracy* yang tinggi menunjukkan bahwa sebagian besar data berhasil diprediksi dengan benar, sedangkan nilai F1 Macro yang tinggi menunjukkan bahwa performa model tidak hanya baik pada kelas mayoritas, tetapi juga cukup seimbang pada beberapa kelas target.

Penggunaan F1 Macro penting karena dataset kualitas udara memiliki distribusi kelas yang tidak seimbang. Jika evaluasi hanya menggunakan *accuracy*, performa model dapat terlihat baik meskipun kelas minoritas tidak dikenali dengan optimal. Oleh karena itu, *precision macro*, *recall macro*, dan F1 macro digunakan untuk memberikan evaluasi yang lebih adil terhadap seluruh kategori kualitas udara.

Pemeriksaan *overfitting* dilakukan menggunakan selisih Train F1 Macro dan Test F1 Macro. Selisih sebesar 0,0303 menunjukkan bahwa model masih mampu melakukan generalisasi pada data uji. Kondisi ini menunjukkan bahwa model tidak hanya menghafal data latih, tetapi juga dapat mengenali pola pada data baru yang tidak digunakan saat pelatihan.

Pada sisi *clustering*, nilai Silhouette Score sebesar 0,2031 menunjukkan bahwa pemisahan antar cluster belum sangat kuat. Namun, hasil *clustering* tetap berguna sebagai analisis pendukung karena tujuan *clustering* pada proyek ini bukan menggantikan kategori resmi, melainkan memberikan informasi tambahan mengenai pola kemiripan antar data kualitas udara.

Balance Score sebesar 0,9795 dan Imbalance Ratio sebesar 1,0210 menunjukkan bahwa hasil cluster relatif seimbang. Distribusi yang seimbang membantu interpretasi karena tidak ada cluster yang terlalu mendominasi atau terlalu kecil. Dengan demikian, K-Means masih dapat digunakan untuk memberikan segmentasi pola kualitas udara yang mudah dijelaskan.

Interpretasi cluster dilakukan berdasarkan rata-rata parameter polutan. Cluster dengan rata-rata polutan lebih rendah disebut sebagai Cluster Baik, sedangkan cluster dengan rata-rata polutan lebih tinggi diinterpretasikan sebagai Cluster Sedang, Cluster Tidak Sehat, dan Cluster Sangat Tidak Sehat. Interpretasi ini membuat hasil *unsupervised learning* lebih mudah dipahami oleh pengguna aplikasi.

Kombinasi *classification* dan *clustering* membuat hasil penelitian lebih lengkap. *Classification* memberikan output prediktif yang langsung menjawab kategori kualitas udara, sedangkan *clustering* memberikan insight tambahan mengenai pola kelompok data. Dengan demikian, pengguna tidak hanya mendapatkan label prediksi, tetapi juga informasi tentang segmentasi pola kualitas udara.

Dalam implementasi aplikasi, hasil *classification* menjadi keluaran utama karena pengguna membutuhkan informasi kategori kualitas udara. Sementara itu, hasil *clustering* ditampilkan sebagai informasi pendukung agar pengguna memahami pola polutan yang mirip dengan data historis tertentu. Hal ini sesuai dengan tujuan proyek untuk membangun aplikasi analisis dan prediksi yang interaktif.

Pemilihan Random Forest sebagai model *classification* juga didukung oleh kemampuannya dalam mengukur tingkat kepentingan fitur. Informasi *feature importance* membantu menjelaskan parameter mana yang lebih dominan terhadap prediksi kualitas udara. Pada kasus kualitas udara, fitur seperti PM2.5 dan PM10 umumnya memiliki kontribusi penting karena sering berkaitan langsung dengan kategori pencemaran.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model yang dibangun telah layak untuk *deployment*. Model *classification* memiliki performa tinggi dan model *clustering* mampu memberikan segmentasi yang dapat diinterpretasikan. Keduanya telah disimpan dan digunakan pada tahap *deployment* aplikasi web berbasis Streamlit.

V. IMPLEMENTASI SISTEM

Implementasi sistem dilakukan dengan membuat aplikasi web berbasis Streamlit. Aplikasi ini menjadi wujud *deployment* dari model yang telah dibangun dan dievaluasi. Tujuan utama aplikasi adalah memudahkan pengguna dalam memasukkan nilai parameter polutan dan memperoleh hasil prediksi kategori kualitas udara serta hasil cluster.

Aplikasi memiliki beberapa menu utama, yaitu Home, Dataset Overview, Prediction/Analysis, Visualization, dan About. Menu Home berisi judul, deskripsi singkat, dan identitas kelompok. Dataset Overview menampilkan informasi dataset, jumlah data, statistik, dan tampilan data. Prediction/Analysis berisi form input pengguna. Visualization menampilkan grafik pendukung. About menjelaskan metode, dataset, dan informasi proyek.

Cara kerja sistem dimulai ketika pengguna memasukkan nilai PM2.5, PM10, SO2, CO, O3, dan NO2. Input tersebut diproses agar sesuai dengan format model. Random Forest Classifier kemudian menghasilkan prediksi kategori kualitas udara, sedangkan K-Means Clustering menghasilkan label cluster. Hasil akhir ditampilkan dalam bentuk teks, interpretasi, dan visualisasi pendukung.

File model disimpan agar aplikasi tidak perlu melatih ulang model setiap kali dijalankan. File yang digunakan meliputi `model_classification_random_forest.pkl`, `model_clustering_kmeans.pkl`, `scaler_classification.pkl`, `scaler_clustering.pkl`, dan `cluster_label_map.pkl`. Selain itu, repository juga memuat `app.py`, `notebook analisis`, `dataset`, `requirements.txt`, dan `README.md`.

Repository project tersedia pada https://github.com/farrelfaricaf/UAS_DataMining_Kelompok-14_KDD1/. Aplikasi web dapat diakses melalui <https://kualitas-udara-kelompok-14kdd1.streamlit.app/>. Dengan adanya deployment, proyek tidak hanya berhenti pada notebook, tetapi dapat digunakan dalam bentuk aplikasi web interaktif.

TABEL IX
KOMPONEN IMPLEMENTASI SISTEM

Komponen	Keterangan
Framework aplikasi	Streamlit
File aplikasi	<code>app.py</code>
Model classification	<code>model_classification_random_forest.pkl</code>
Model clustering	<code>model_clustering_kmeans.pkl</code>
Scaler	<code>scaler_classification.pkl</code> dan <code>scaler_clustering.pkl</code>
Mapping cluster	<code>cluster_label_map.pkl</code>
Repository	GitHub
Deployment	Streamlit Cloud

VI. KESIMPULAN

Penelitian ini berhasil menerapkan pendekatan Data Mining untuk memprediksi dan mengelompokkan kualitas udara Jakarta berdasarkan parameter polutan PM2.5, PM10, SO2, CO, O3, dan NO2. Framework CRISP-DM membantu proses pengerjaan menjadi sistematis, mulai dari business understanding hingga deployment.

Pada tahap data preparation, dataset dibersihkan dari duplikasi sehingga diperoleh 3.892 data bersih. Target classification dipetakan menjadi empat kategori, yaitu Baik, Sedang, Tidak Sehat, dan Sangat Tidak Sehat. Data latih diseimbangkan menggunakan SMOTE dan fitur numerik diskalakan menggunakan RobustScaler.

Model classification menggunakan Random Forest Classifier memperoleh Accuracy Test sebesar 0,9820 dan F1 Macro Test sebesar 0,9685. Selisih Train-Test F1 Macro sebesar 0,0303 menunjukkan bahwa model tidak terindikasi overfitting. Dengan demikian, model Random Forest layak digunakan sebagai model utama untuk prediksi kategori kualitas udara Jakarta.

Model clustering menggunakan K-Means Clustering menghasilkan empat cluster yang diinterpretasikan sebagai Cluster Baik, Cluster Sedang, Cluster Tidak Sehat, dan Cluster Sangat Tidak Sehat. Meskipun nilai Silhouette Score belum sangat tinggi, hasil clustering tetap bermanfaat sebagai insight tambahan untuk memahami pola kemiripan kualitas udara berdasarkan parameter polutan.

Hasil akhir penelitian telah diimplementasikan dalam aplikasi web berbasis Streamlit. Aplikasi tersebut memungkinkan pengguna memasukkan nilai parameter polutan, memperoleh prediksi kategori kualitas udara, melihat hasil cluster, dan mengakses visualisasi pendukung. Pengembangan selanjutnya dapat menambahkan data real-time API, fitur lokasi, model advanced, dan Explainable AI seperti SHAP atau LIME.

UCAPAN TERIMA KASIH

Penulis memanjatkan puji syukur ke hadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan penyertaan-Nya sehingga penelitian serta penyusunan artikel penelitian yang berjudul “Prediksi dan Clustering Kualitas Udara Jakarta Menggunakan Random Forest dan K-Means Clustering” dapat diselesaikan dengan baik. Seluruh proses penelitian, mulai dari

pengumpulan data, pengolahan dataset, pembangunan model, evaluasi, hingga implementasi sistem, dapat terlaksana berkat dukungan dari berbagai pihak.

Penulis menyampaikan terima kasih yang sebesar-besarnya kepada Dr. Wiyli Yustanti, S.Si., M.Kom., selaku dosen pengampu mata kuliah Data Mining yang telah memberikan bimbingan, arahan, wawasan, serta berbagai masukan yang sangat bermanfaat selama proses perkuliahan dan pengerjaan proyek penelitian ini. Materi yang diberikan selama perkuliahan menjadi landasan penting dalam memahami konsep Data Mining, Machine Learning, metodologi CRISP-DM, serta penerapan algoritma Random Forest dan K-Means Clustering dalam menyelesaikan permasalahan nyata berbasis data.

Ucapan terima kasih juga penulis sampaikan kepada anggota kelompok yang telah bekerja sama secara aktif dalam setiap tahapan penelitian. Mulai dari proses pencarian referensi, pengumpulan dataset, eksplorasi data, pembersihan data, pembangunan model, pengujian performa, hingga pengembangan aplikasi berbasis Streamlit dilakukan melalui kolaborasi yang baik sehingga penelitian dapat berjalan sesuai dengan tujuan yang telah ditetapkan.

Selain itu, penulis juga mengucapkan terima kasih kepada penyedia dataset dari Kaggle dan Data.go.id yang telah menyediakan data kualitas udara Jakarta secara terbuka sehingga penelitian ini dapat dilaksanakan. Penulis berharap penelitian ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya dalam bidang Data Mining dan analisis kualitas udara, serta dapat menjadi referensi bagi penelitian selanjutnya yang mengangkat topik serupa.

REFERENSI

- [1] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, dan R. Wirth, "CRISP-DM 1.0: Step-by-step data mining guide," SPSS Inc., 2000.
- [2] J. Han, M. Kamber, dan J. Pei, Data Mining: Concepts and Techniques, 3rd ed. Waltham, MA: Morgan Kaufmann, 2012.
- [3] L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, hal. 5-32, 2001.
- [4] J. MacQueen, "Some methods for classification and analysis of multivariate observations," Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, vol. 1, hal. 281-297, 1967.
- [5] N. V. Chawla, K. W. Bowyer, L. O. Hall, dan W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," Journal of Artificial Intelligence Research, vol. 16, hal. 321-357, 2002.
- [6] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, hal. 2825-2830, 2011.
- [7] Streamlit, "Streamlit documentation," [Online]. Tersedia: <https://docs.streamlit.io/>. Diakses: 27 Mei 2026.
- [8] Derry Derajat, "Indeks Pencemaran Udara DKI," Kaggle. [Online]. Tersedia: <https://www.kaggle.com/datasets/derryderajat/indeks-pencemaran-udara-dki>. Diakses: 27 Mei 2026.
- [9] Senadu34, "Air Quality Index in Jakarta 2010-2021," Kaggle. [Online]. Tersedia: <https://www.kaggle.com/datasets/senadu34/air-quality-index-in-jakarta-2010-2021>. Diakses: 27 Mei 2026.
- [10] Data.go.id, "Data Indeks Standar Pencemar Udara ISPU di Provinsi DKI Jakarta," [Online]. Tersedia: <https://data.go.id/dataset/dataset/data-indeks-standar-pencemar-udara-ispu-di-provinsi-dki-jakarta>. Diakses: 27 Mei 2026.
- [11] Data.go.id, "Indeks Standar Pencemaran Udara ISPU Tahun 2013," [Online]. Tersedia: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2013>. Diakses: 27 Mei 2026.
- [12] Data.go.id, "Indeks Standar Pencemaran Udara ISPU Tahun 2012," [Online]. Tersedia: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2012>. Diakses: 27 Mei 2026.
- [13] Data.go.id, "Indeks Standar Pencemaran Udara ISPU Tahun 2011," [Online]. Tersedia: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2011>. Diakses: 27 Mei 2026.

- [14] Data.go.id, “Indeks Standar Pencemaran Udara ISPU Tahun 2010,” [Online]. Tersedia: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2010>. Diakses: 27 Mei 2026.
- [15] IQAir, “Air quality ranking Indonesia,” [Online]. Tersedia: <https://www.iqair.com/>. Diakses: 27 Mei 2026.
- [16] BMKG, “Informasi konsentrasi partikulat PM2.5,” [Online]. Tersedia: <https://www.bmkg.go.id/>. Diakses: 27 Mei 2026.
- [10] Link Video Presentasi dan Demo Aplikasi: <https://drive.google.com/drive/folders/14SHIO3noJxJB3SQzNnvcWPXcZt895nwd?usp=sharing>
- [11] Link Source Code Jupyter Notebook: <https://colab.research.google.com/drive/1yjVEDAmorP6fmRp2tOFoLNxrPbnPawze?usp=sharing>
- [12] Link Repository Project: https://github.com/farrelfaricaf/UAS_DataMining_Kelompok-14_KDD1/

LAMPIRAN

- [1] Link Dataset Utama (final_dataset.csv): https://drive.google.com/file/d/1T-k8dbliVoAzXkCd_hXEU_jrEhEtsREY/view?usp=drive_link
- [2] Link Dataset 1: <https://www.kaggle.com/datasets/derryderajat/indeks-pencemaran-udara-dki>
- [3] Link Dataset 2: <https://www.kaggle.com/datasets/senadu34/air-quality-index-in-jakarta-2010-2021>
- [4] Link Dataset 3: <https://data.go.id/dataset/dataset/data-indeks-standar-pencemar-udara-ispu-di-provinsi-dki-jakarta>
- [5] Link Dataset 4: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2013>
- [6] Link Dataset 5: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2012>
- [7] Link Dataset 6: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2011>
- [8] Link Dataset 7: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2010>
- [9] Link Aplikasi Web: <https://kualitas-udara-kelompok-14kdd1.streamlit.app/>